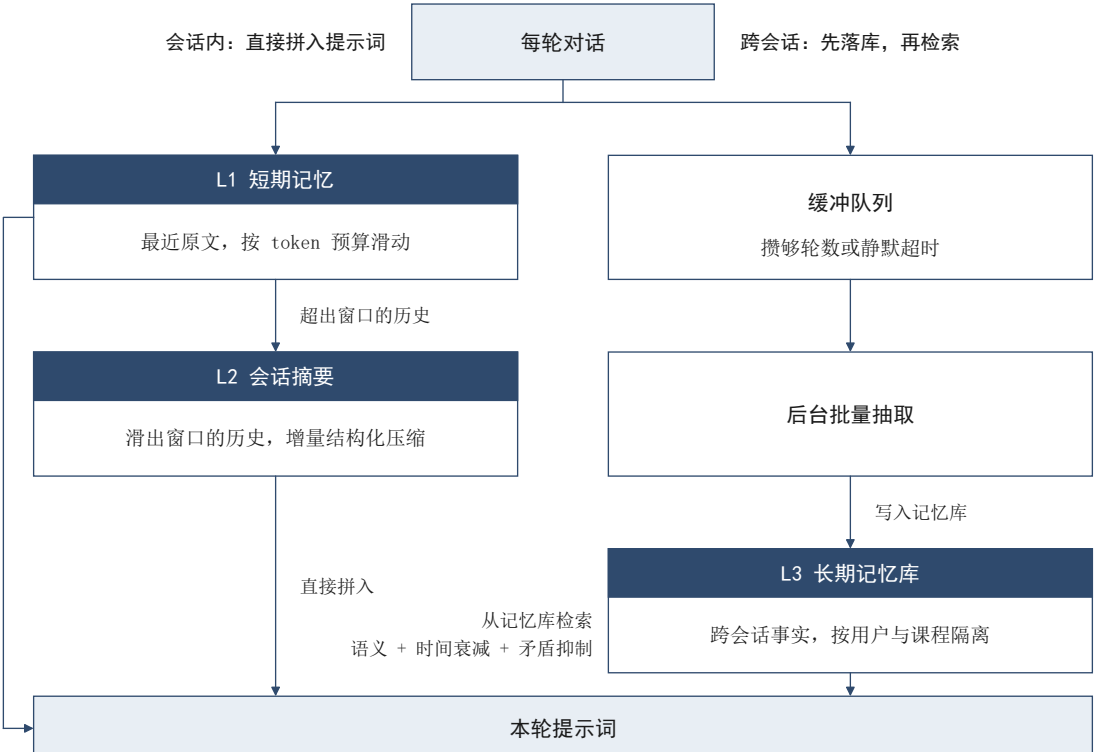
会话内：直接拼入提示词
每轮对话
跨会话：先落库，再检索
L1 短期记忆
最近原文，按 token 预算滑动
缓冲队列
攒够轮数或静默超时
超出窗口的历史
L2 会话摘要
滑出窗口的历史，增量结构化压缩
后台批量抽取
写入记忆库
L3 长期记忆库
直接拼入
从记忆库检索
语义 + 时间衰减 + 矛盾抑制
跨会话事实，按用户与课程隔离
本轮提示词