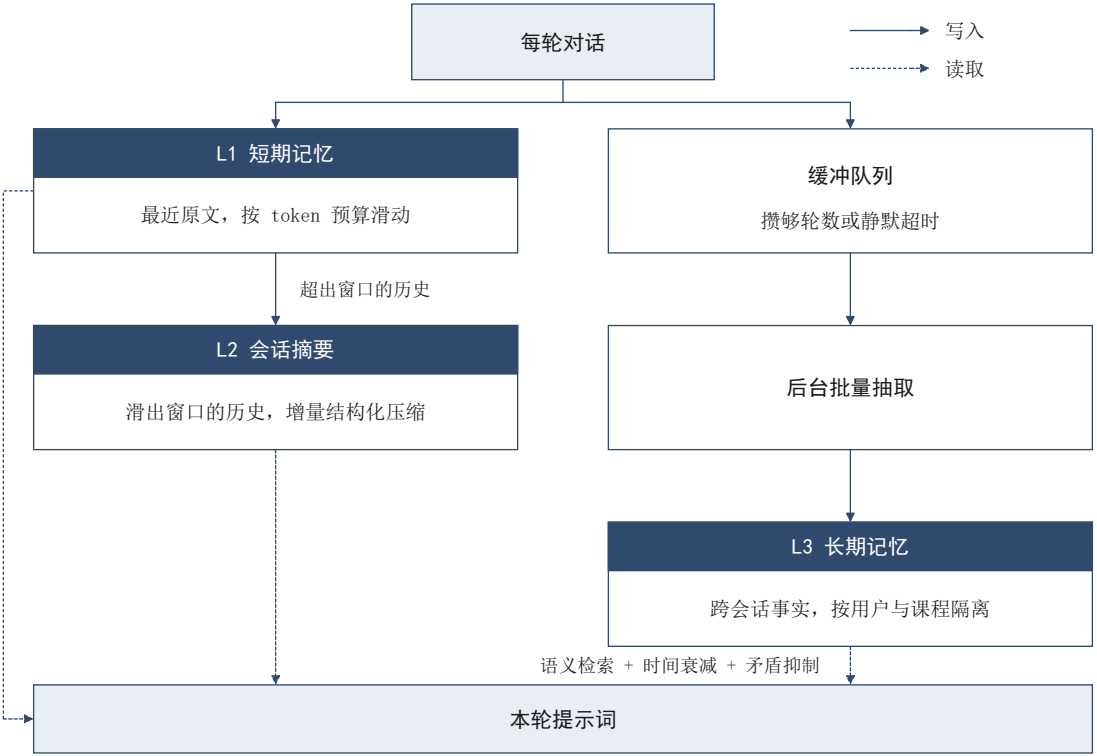
每轮对话
写入
读取
L1 短期记忆
最近原文，按 token 预算滑动
超出窗口的历史
L2 会话摘要
滑出窗口的历史，增量结构化压缩
缓冲队列
攒够轮数或静默超时
后台批量抽取
L3 长期记忆
跨会话事实，按用户与课程隔离
语义检索 + 时间衰减 + 矛盾抑制
本轮提示词